

杭州学区房数据分析项目计划书

一、项目基本信息

项目	内容
项目名称	杭州学区房数据分析与房价预测
项目类型	数据分析与机器学习
团队人数	4人
项目周期	4.5小时（3个阶段，每阶段90分钟）
指导教师	陶建敏
小组成员	见下表

二、团队分工

角色	姓名	学号	主要职责
组长	苏毅	223850115	项目统筹、进度管理、任务分配、报告审核
组员1	李文锋	223850114	阶段一：数据清洗与特征提取
组员2	梁俊杰	223850109	阶段二：模型训练与交叉验证
组员3	林文彬	223850102	阶段三：模型优化与报告撰写

组长职责

- 制定项目计划，分配任务
- 监督各阶段进度，协调组员工作
- 审核代码质量和实验结果
- 组织团队讨论，解决技术问题
- 最终报告的汇总和提交

三、项目目标

3.1 业务目标

预测杭州学区房的单价，为购房者提供价格参考，帮助评估学区房价格是否合理，辅助投资决策。

3.2 技术目标

- 完成数据探索性分析（EDA）

- 构建房价预测回归模型
- 分析影响房价的关键因素
- 实现模型融合提升预测精度

3.3 预期成果

- 完整的分析报告
- 可复用的代码模块
- 训练好的预测模型
- 业务洞察与建议

四、技术方案

4.1 技术栈

类别	技术/工具
编程语言	Python 3.9+
数据处理	pandas, numpy
机器学习	scikit-learn
可视化	matplotlib, seaborn
开发环境	Jupyter Notebook / VS Code

4.2 算法选型


模型	类型	用途
线性回归	线性模型	基线模型
随机森林	Bagging集成	主力模型
梯度提升(GBDT)	Boosting集成	主力模型
Stacking融合	模型融合	最终模型

4.3 评估指标

指标	说明	目标值
R ²	决定系数	> 0.80
RMSE	均方根误差	越小越好
MAE	平均绝对误差	越小越好

五、项目计划

5.1 时间安排



5.2 详细任务分解

阶段一：数据获取、探索分析与特征工程基础 (90分钟)

时间	任务	负责人	产出
0-10min	理解业务问题与字段角色	全员	业务理解文档
10-25min	读取数据并检查结构	李文锋	数据结构报告
25-40min	数据质量评估	李文锋	质量评估表
40-55min	基础统计描述	李文锋+苏毅	统计描述表
55-75min	数据清洗与特征提取	李文锋	清洗后数据
75-90min	阶段总结与检查	苏毅	阶段报告

阶段二：深度特征工程与多模型训练 (90分钟)

时间	任务	负责人	产出
0-10min	回顾与规划	梁俊杰	特征工程计划
10-30min	深度特征工程	梁俊杰	衍生特征
30-45min	系统性可视化分析	梁俊杰	可视化图表
45-55min	类别编码与数据准备	梁俊杰	建模数据
55-75min	多模型训练	梁俊杰	训练好的模型
75-90min	交叉验证与对比	梁俊杰+苏毅	模型对比表

阶段三：迭代优化与模型评估（90分钟）

时间	任务	负责人	产出
0-25min	超参调优	林文彬	调优后模型
25-40min	模型融合与集成	林文彬	融合模型
40-55min	模型评估与可视化	林文彬	评估图表
55-70min	特征重要性与业务洞察	林文彬+苏毅	业务建议
70-85min	实验报告撰写	全员	实验报告
85-90min	总结与提交	苏毅	最终提交包

六、数据说明

6.1 数据来源

杭州二手房交易数据，包含学区房相关信息。

6.2 数据规模

- 样本数量：9200条
- 特征数量：26个
- 目标变量：单价（元/平米）

6.3 主要字段

字段	类型	说明
建筑面积	数值	房屋面积（平方米）
户型	文本	如3室2厅
楼层	类别	低层/中层/高层
朝向	类别	南/南北/东南等
建筑年代	数值	建造年份
单价（元/平米）	数值	目标变量
总价（万元）	数值	房屋总价
所在学校	文本	对应学校
距离学校	文本	与学校距离
所在区县	类别	区域位置

七、预期结果

7.1 模型性能

模型	预期R ²	实际R ²
线性回归（基线）	0.50-0.60	0.5474
随机森林	0.75-0.85	0.8411
梯度提升	0.75-0.85	0.8264
Stacking融合	0.80-0.90	0.8409

7.2 业务洞察

- 1. 建筑面积是影响房价的最重要因素
- 2. 学校等级评分对房价有显著影响
- 3. 距离学校越近，房价越高
- 4. 房龄影响房价，次新房价格最高
- 5. 楼层对房价有影响，高层和中层更受欢迎

八、风险管理

风险	影响	应对措施
数据质量问题	模型效果差	严格数据清洗，多重验证
模型过拟合	泛化能力差	交叉验证，正则化
时间不足	任务未完成	优先核心任务，合理分工
技术难题	进度延误	及时讨论，寻求帮助

九、提交材料

9.1 代码文件

```
experiment_06/  
├─ notebooks/  
│   └─ 阶段一_完整代码.py  
│   └─ 阶段二_完整代码.py  
│   └─ 阶段三_完整代码.py  
├─ src/                # 可复用模块  
├─ models/             # 训练好的模型  
├─ figures/            # 可视化图表  
└─ reports/            # 实验报告
```

9.2 文档材料

- ☐ 项目计划书（本文档）
- ☐ 实验报告
- ☐ 代码说明文档
- ☐ 数据分析报告

9.3 演示材料

- ☐ PPT演示文稿
- ☐ 项目演示视频（可选）

十、评分标准

评分项	分值	说明
数据清洗与特征工程	25%	缺失值处理、特征构造
模型训练与评估	30%	模型选择、交叉验证
模型优化与融合	20%	超参调优、模型融合
可视化与分析	15%	图表质量、业务洞察
报告与演示	10%	报告规范、表达清晰

项目计划书编制：组长 苏毅

编制日期：2026年6月

组员：

- 李文锋
- 梁俊杰
- 林文彬